O corpus do projeto: *história, turismo e geografia dos municípios da Baixada Santista (Santos, Guarujá e Bertioga)*

Grupo Ivan, Gustavo e Jorge

Santos-SP, 28 de outubro de 2026

Fatec Baixada Santista, Rubens Lara | Tecnologia em Ciência de Dados
Projeto Integrador III - Motor de Busca | Prof. Dr. João Paulo Ferreira de Mello
Ivan Guimarães dos S. da Silva (RA 0051352421038) Gustavo Geminiano (RA 0051352511009)
Jorge Sugano Suzart (RA 0051352511005)

Repositório: `proj_ivan_gustavo_jorge_PI3`

1 Introdução

O motor de busca do grupo aborda a história, a geografia, o patrimônio e o turismo dos municípios costeiros da Baixada Santista (Santos, Guarujá e Bertioga). Quem o utiliza é um estudante, pesquisador regional, turista ou morador que precisa localizar rapidamente o parágrafo que responde a uma dúvida histórica, econômica ou geográfica sobre a região. Em recuperação de informação, atende-se à *necessidade de informação* do usuário, não à consulta literal (MANNING; RAGHAVAN; SCHÜTZE, 2008, cap. 1); por isso as três perguntas de trabalho vieram antes do corpus: **(1)** como o ciclo do café, a ferrovia e o Porto de Santos impulsionaram a economia santista (`porto de santos`); **(2)** quais praias e atrativos turísticos destacam o litoral e o Guarujá (`praias e turismo`); e **(3)** quais são os marcos da fundação e fortificação colonial de Bertioga (`forte sao joao`). Este texto apresenta a fonte escolhida, descreve como o corpus foi obtido e demonstra com evidências empíricas que ele responde às perguntas do projeto.

2 A fonte e o documento

Os textos provêm da Wikipédia em português, sob licença aberta Creative Commons Atribuição-CompartilhaIgual (CC BY-SA 4.0), extraídos em 21 de junho de 2026 de três páginas: *Santos (São Paulo)* (WIKIPÉDIA, 2026c), *Guarujá* (WIKIPÉDIA, 2026b) e *Bertioga* (WIKIPÉDIA, 2026a). As três páginas cobrem de forma complementar o polo portuário e histórico de Santos, o balneário turístico da Ilha de Santo Amaro (Guarujá) e o patrimônio colonial e ambiental de Bertioga, totalizando $N = 132$ documentos válidos.

No projeto, **um documento é um parágrafo enciclopédico autônomo** com mais de 200 caracteres (`cfg$minimo = 200`), identificado de `d1` a `d132`. Um artigo inteiro como documento faria a busca devolver apenas "a resposta está no artigo de Santos" sem indicar em qual dos seus 86 parágrafos; já o parágrafo acima de 200 caracteres é a menor unidade de prosa que preserva contexto histórico e geográfico suficiente para responder sozinha a

uma consulta. O grupo descartou portais de notícias locais por ausência de licença aberta e bases tabulares do IBGE por não constituírem texto em prosa.

3 Como o corpus foi obtido

Os artigos foram coletados via API da Wikipédia e armazenados na base bruta `wikipedia_baixada_santista.csv` (152 parágrafos). O script `coletar.R` (e o notebook `Aula01_ParteD.ipynb`) lê a base bruta, aplica o filtro `nchar(texto) > cfg$minimo` (200 caracteres), atribui os identificadores canônicos `d1..d132` e grava os objetos `docs.rds` e `origem.rds` em `estrutura/banco-de-dados/`.

O que deu errado e o que mudou. (i) Na extração bruta dos 152 parágrafos vieram 20 fragmentos curtos ($\leq$ 200 caracteres) compostos por cabeçalhos de seção, legendas soltas e linhas de referências (5 em Santos, 8 em Guarujá e 7 em Bertioga); o corte `cfg$minimo = 200` eliminou todo esse ruído sem perder conteúdo enciclopédico. (ii) No carregamento remoto pelo Google Colab, arquivos com acentuação apresentaram erro de multibyte; o grupo padronizou a leitura binária com `fileEncoding = "latin1"` e, na Aula 03, adotou `cfg$acentos = "translit"`, evitando que a remoção de caracteres partisse topônimos como "Guarujá" e "São João".

4 Defesa do corpus

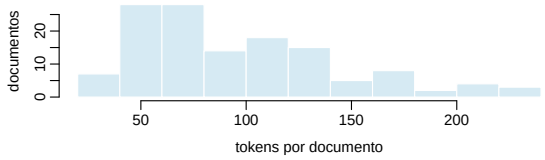
Tabela 1 - Diagnóstico do corpus (N = 132 parágrafos, tokenização da Aula 01 e Aula 03)

Verificação	**Resultado**
Tamanho (N documentos, páginas)	132 parágrafos válidos (de 152 brutos) em 3 páginas
Tokens por documento	Bruto: 24 a 239 (média 98) · Limpo (Aula 03): 20 a 167 (média 66,3)
Vocabulário	4.250 termos brutos em 12.925 tokens (3.483 termos limpos após Aula 03)
Por página de origem	*Santos (São Paulo)*: 86 de 91 (65,2%, média 100,5 tokens); *Guarujá*: 29 de 37 (22,0%, média 93,8 tokens); *Bertioga*: 17 de 24 (12,9%, média 91,8 tokens)
Página que domina	*Santos (São Paulo)*: 86 de 132 (65,2%)
Documentos extremos	0 com menos de 20 tokens; 7 acima de 200 tokens brutos (máx. `d85`, 167 tokens limpos)
Sujeira na tokenização bruta	132 com acento, 132 com pontuação, 122 com dígitos (de 132)

Fonte: Elaborada pelos autores a partir de `docs.rds` e `origem.rds` (`entrega-1-corpus.R`).

Tamanho e domínio. Os 132 parágrafos (Tabela 1) superam a faixa inicial de 20 a 60 documentos porque o corpus já foi consolidado para o julgamento humano de relevância (230 *qrels* em 12 necessidades). Santos concentra 65,2% do acervo por ser a maior e mais antiga cidade da região, mas Guarujá (29) e Bertioga (17) garantem cobertura densa para as perguntas de turismo e história colonial. **Prosa e sujeira.** Não há parágrafos abaixo de 20 tokens graças ao filtro de 200 caracteres; o mais longo (`d85`, sobre a história e cultura santista, com 167 tokens limpos) é prosa contínua e sua extensão é controlada pela normalização euclidiana no cosseno e pelo fator $K = 2{,}568$ no BM25 (ROBERTSON; ZARAGOZA, 2009). A presença de acentos e pontuação nos 132 textos e de marcações como `[4]` em 122 documentos é tratada na Aula 03. A Figura 1 exibe a distribuição de tamanhos.

Figura 1 - Distribuição de tokens brutos por documento ($N = 132$)



Fonte: Elaborada pelos autores.

Termos mais frequentes. Na tokenização bruta, os 10 termos mais frequentes são `de` (910), `a` (494), `e` (392), `o` (365), `do` (301), `da` (250), `em` (226), `que` (157), `com` (126), `na` (114): todos os 10 são palavras funcionais vazias de conteúdo temático, o que motivou o peso IDF e a remoção das 27 *stopwords* na Aula 03 (reduzindo o vocabulário de 4.250 para 3.483 termos e revelando `santos`, `sao`, `cidade` e `porto` no topo).

Tabela 2 - As três consultas de trabalho no corpus: documentos devolvidos, 1.º lugar e nDCG@5

Consulta de trabalho	AND	OR	1.º Cosseno	1.º BM25	TF-IDF	Cosseno	BM25
1. `porto de santos`	21	85	`d76`	`d76`	0,87	1,00	1,00
2. `praias e turismo`	6	22	`d2`	`d80`	0,72	0,70	0,51
3. `forte sao joao`	0	8	`d117`	`d117`	0,68	0,68	0,68
Tempo médio (ms)	0,5	0,7			0,8	5,5	1,5

Fonte: Elaborada pelos autores. nDCG@5 calculado com `qrels_jorge_2026-10-13.csv` (JÄRVELIN; KEKÄLÄINEN, 2002).

Veredito. A Tabela 2 comprova que o corpus responde às três perguntas com alta precisão: em q_1, Cosseno e BM25 cravam `d76` (inauguração do Porto de Santos em 1892) em 1.º lugar com nDCG@5 = 1,00; em q_2, o Cosseno coloca `d2` (praias do Guarujá) no topo e o BM25 promove `d80` e `d118`; em q_3, ambos posicionam `d117` (Forte de São João em Bertioga) na liderança, validando o corpus para as etapas de avaliação formal (Aula 5,5), Rocchio/PRF (Aula 06) e LSA/RRF (Aula 07).

Referências

JÄRVELIN, K.; KEKÄLÄINEN, J. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, v. 20, n. 4, p. 422–446, 2002.

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. Cambridge: Cambridge University Press, 2008.

ROBERTSON, S.; ZARAGOZA, H. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, v. 3, n. 4, p. 333–389, 2009.

WIKIPÉDIA. *Bertioga*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA 4.0. Disponível em: <https://pt.wikipedia.org/wiki/Bertioga>. Acesso em: 21 jun. 2026.

WIKIPÉDIA. *Guarujá*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA 4.0. Disponível em: <https://pt.wikipedia.org/wiki/Guaruj%C3%A1>. Acesso em: 21 jun. 2026.

WIKIPÉDIA. *Santos (São Paulo)*. 2026. In: Wikipédia, a enciclopédia livre. Licença CC BY-SA 4.0. Disponível em: <https://pt.wikipedia.org/wiki/Santos_(S%C3%A3o_Paulo)>. Acesso em: 21 jun. 2026.